

Gesamtanalyse der GEMM-Ergebnisse

Die kombinierte Auswertung der GEMM-Kampagnen auf dem Intel Core i9-7900X, dem AMD Threadripper 3970X, der NVIDIA GeForce RTX 3090 und der NVIDIA GeForce RTX 5060 Ti zeigt, dass die energie- und laufzeitoptimale Ausführungsplattform deutlich von der Matrixgröße abhängt. Die Daten bilden damit keinen einfachen, über alle Problemgrößen konstanten Hardware-Winner ab. Stattdessen lassen sich mehrere Größenregime unterscheiden, in denen sich sowohl die bevorzugte Plattform als auch das Verhältnis zwischen Energieverbrauch und Laufzeit verändert.

Die Analyse basiert auf fünf unabhängig ausgeführten Sessions pro Konfiguration. Die jeweils zehn Wiederholungen innerhalb einer Session werden als technische Wiederholungen betrachtet; die statistischen Vergleiche verwenden die fünf Session-Mediane als primäre Wiederholungseinheiten. Für jede Plattform und Matrixgröße wurden Laufzeit, Energie pro GEMM und das daraus abgeleitete Energy-Delay Product untersucht. Zusätzlich werden Durchsatz und GFLOP/J zur anschaulichen Darstellung berichtet. Diese beiden Größen stellen jedoch keine unabhängigen zusätzlichen Zielgrößen dar: Der Durchsatz ist bei gleicher logischer Arbeit der Kehrwert der Laufzeit, während GFLOP/J der Kehrwert der Energie pro Operation ist. Entsprechend stützt sich die eigentliche Entscheidungsanalyse auf die zwei grundlegenden Achsen Laufzeit und Energie; das EDP dient als zusammengesetzter Kompromissindikator.

Größenabhängige Plattformregime

Bei der kleinsten untersuchten Matrixgröße $N=64$ ist die Intel-CPU sowohl laufzeit- als auch energieoptimal. Die GPUs können ihre höhere Rechenleistung in diesem Größenbereich nicht ausreichend auslasten, während Launch- und Steuerungskosten im Verhältnis zur eigentlichen Rechenarbeit stark ins Gewicht fallen. Der genaue optimale Intel-Threadcount weist eine erhöhte Sessionvariabilität auf. Der Plattformbefund bleibt dennoch robust, da der Abstand zwischen Intel und den beiden GPUs wesentlich größer ist als die Unsicherheit zwischen den einzelnen Intel-Konfigurationen.

Bereits bei $N=128$ verschiebt sich die optimale Ausführung zu den GPUs. Gleichzeitig entsteht ein klarer Energie-Laufzeit-Konflikt zwischen den beiden Grafikkarten: Die RTX 5060 Ti benötigt weniger Boardenergie, während die RTX 3090 die geringere Laufzeit erreicht. Bei $N=128$ ist die Energieeinsparung der RTX 5060 Ti groß genug, dass sie zusätzlich das niedrigere EDP erzielt.

Der gleiche grundlegende Zielkonflikt besteht bei $N=256$: Die RTX 5060 Ti bleibt energieärmer, während die RTX 3090 schneller ist. Im Gegensatz zu $N=128$ ist der Laufzeitvorteil der RTX 3090 hier jedoch bereits so groß, dass das EDP zugunsten der RTX 3090 ausfällt. Damit zeigen $N=128$ und $N=256$ denselben qualitativen Energie-Laufzeit-Konflikt, aber unterschiedliche Resultate für den zusammengesetzten EDP-Indikator.

Bei $N=512$ ist die RTX 3090 klar laufzeitoptimal. Ihr punktuell gemessener Energiebedarf liegt ebenfalls etwas unter dem der RTX 5060 Ti. Das Konfidenzintervall des Energieverhältnisses reicht jedoch in die vorab festgelegte praktische Gleichwertigkeitszone von ± 2 Prozent hinein. Der Energieunterschied wird deshalb nicht als klarer Winner klassifiziert. Der belastbare Befund lautet hier folglich: Die RTX 3090 ist eindeutig schneller, während sich die beiden GPUs hinsichtlich der gemessenen Boardenergie nicht eindeutig unterscheiden lassen.

Ab $N=1024$ zeigt sich ein stabiles Dominanzregime der RTX 3090. Für alle untersuchten Größen von $N=1024$ bis $N=16384$ ist sie sowohl schneller als auch energieärmer als die RTX 5060 Ti. Bei $N=16384$ benötigt die RTX 3090 nur ungefähr 18,5 Prozent der Laufzeit und etwa 34,7 Prozent der Boardenergie der RTX 5060 Ti. Die neuere und nominell sparsamere GPU ist damit bei großen residenten FP32-GEMMs nicht automatisch energieeffizienter. Entscheidend ist vielmehr, wie effizient das jeweilige Gerät die konkrete Rechenoperation ausführen kann. Eine deutlich kürzere Ausführungszeit kann trotz höherer momentaner Leistungsaufnahme zu einer geringeren Gesamtenergie führen.

Insgesamt entstehen damit drei zentrale Ausführungsregime:

1. ein CPU-günstiges Kleinstproblemregime bei $N=64$,
2. ein GPU-Energie-Laufzeit-Trade-off-Regime bei $N=128$ und $N=256$,
3. ein großes Problemregime ab $N=1024$, in dem die RTX 3090 sowohl Laufzeit als auch Energie dominiert.

$N=512$ bildet den Übergangsbereich zwischen dem Trade-off- und dem Dominanzregime.

Direkter Vergleich der beiden GPUs

Der direkte Vergleich zwischen RTX 3090 und RTX 5060 Ti zeigt einen deutlichen, größenabhängigen Crossover. Bei kleinen GEMMs benötigt die RTX 5060 Ti weniger Energie, ist aber erheblich langsamer. Bei $N=128$ ist die RTX 3090 ungefähr 1,9-mal so schnell, benötigt jedoch etwa 2,2-mal so viel Energie. Bei $N=256$ ist sie ungefähr 2,3-mal so schnell und benötigt etwa 1,6-mal so viel Energie.

Mit zunehmender Matrixgröße nimmt der Laufzeitvorteil der RTX 3090 weiter zu, während sich gleichzeitig das Energieverhältnis umkehrt. Spätestens ab $N=1024$ führt die höhere Rechenleistung der RTX 3090 nicht nur zu kürzeren Laufzeiten, sondern auch zu einem geringeren Energiebedarf pro vollständig ausgeführter GEMM. Damit zeigen die Ergebnisse, dass eine niedrigere Boardleistung oder eine neuere GPU-Generation allein keine ausreichende Grundlage für eine energieoptimale Gerätewahl darstellt. Relevant ist die für eine festgelegte Arbeit benötigte Gesamtenergie.

Threadcount-Trade-offs innerhalb der CPUs

Innerhalb der CPU-Plattformen treten deutlich weniger klare Energie-Laufzeit-Konflikte auf als im GPU-Vergleich. Viele scheinbar unterschiedliche exakte Minima verschwinden, sobald praktische Gleichwertigkeit und Unsicherheit zwischen Sessions berücksichtigt werden.

Auf dem AMD-System bleiben jedoch zwei klare Konfigurationskonflikte bestehen. Bei $N=4096$ ist die Ausführung mit 64 Threads energieoptimal, während 32 Threads laufzeitoptimal sind. Der Wechsel von 64 auf 32 Threads verkürzt die Laufzeit um ungefähr 6,7 Prozent, erhöht den Energiebedarf jedoch um etwa 7,7 Prozent. Bei $N=16384$ reduziert die 32-Thread-Konfiguration die Laufzeit um ungefähr 4,8 Prozent, benötigt dafür jedoch rund 8,8 Prozent mehr Energie als die 64-Thread-Konfiguration.

Diese beiden Fälle sind belastbare Beispiele dafür, dass maximale Parallelität beziehungsweise minimale Laufzeit innerhalb derselben Plattform nicht zwingend mit minimalem Energieverbrauch zusammenfällt. Der Trade-off ist allerdings auf wenige große GEMM-Konfigurationen begrenzt. GEMM allein liefert daher keine breit ausgeprägte Fastest-versus-Greenest-Landschaft über alle Größen und Geräte hinweg.

Stabilität und statistische Einordnung

Die GPU-Kampagnen weisen eine sehr hohe Wiederholbarkeit auf. Für beide GPUs wurden keine hinsichtlich Laufzeit, Energie oder Durchsatz instabilen Größen identifiziert. Die beobachtete Variabilität konzentriert sich überwiegend auf die CPU-Konfigurationen und dort insbesondere auf das thermisch begrenzte Intel-System.

Die Intel-Ergebnisse charakterisieren deshalb das nachhaltige Verhalten des konkret gemessenen Systems unter seinen realen thermischen Randbedingungen. Sie dürfen nicht als thermisch normalisierter Architekturvergleich verallgemeinert werden. Gleichzeitig bedeutet eine instabile Threadkonfiguration nicht automatisch, dass die übergeordnete Plattformscheidung unsicher ist. So ist bei `N=64` die genaue Wahl des Intel-Threadcounts variabel, während der Vorsprung der Intel-Plattform gegenüber den GPUs dennoch klar bleibt.

Die Native-best-Konfigurationen wurden aus denselben fünf Sessions ausgewählt, aus denen anschließend die Effekte und Konfidenzintervalle bestimmt wurden. Die resultierenden Intervalle sind daher als deskriptive Post-Selection-Auswertung zu verstehen. Sie quantifizieren die Wiederholbarkeit der beobachteten Konfigurationen auf den gemessenen Systemen, stellen jedoch keine unverzerrte populationsstatistische Aussage über alle möglichen CPUs, GPUs oder Konfigurationen dar.

Messgrenzen und Energievergleich

Die GPU-Kampagnen messen residentes GEMM. Allokation, Initialisierung und PCIe-Transfers liegen außerhalb des Messfensters. Die Ergebnisse gelten daher für ein Ausführungsszenario, in dem sich die benötigten Daten bereits auf der GPU befinden oder über mehrere Berechnungen wiederverwendet werden. Sie bilden keine vollständige End-to-End-Ausführung einschließlich Host-Device-Kommunikation ab.

Darüber hinaus unterscheiden sich die Energiegrenzen der CPU- und GPU-Messungen. Die GPU-Energie wird über NVML als Boardenergie erfasst und umfasst damit unter anderem den Grafikspeicher. Die gegenwärtige kombinierte GEMM-Auswertung verwendet auf der CPU-Seite Package-RAPL. Dies ist kein symmetrischer Whole-System-Vergleich und muss in allen geräteübergreifenden Energieaussagen ausdrücklich offengelegt werden.

Für die spätere workloadübergreifende Hauptanalyse sollte CPU `Package + DRAM` als primäre Energiegröße verwendet werden, weil diese Messgrenze der GPU-Boardenergie konzeptionell näher kommt als Package-only. Package-only sollte ergänzend als Sensitivitätsanalyse erhalten bleiben. Auch Package plus DRAM und GPU-Boardenergie sind nicht vollständig symmetrisch, reduzieren jedoch die auffälligste Speicherenergie-Asymmetrie. Vor einer Zusammenführung mit den weiteren Workloads muss diese Regel einheitlich festgelegt und über alle Auswertungen hinweg beibehalten werden.

Gesamtinterpretation

Die GEMM-Ergebnisse sind konsistent, statistisch belastbar und wissenschaftlich verwertbar. Ihr stärkster Beitrag liegt in der klaren Größenabhängigkeit der Gerätewahl. Eine statische Regel wie „GPU ist immer besser“, „neuere GPU ist immer sparsamer“ oder „schnellste Konfiguration ist immer energieoptimal“ wird durch die Daten nicht gestützt.

Stattdessen zeigen die Messungen, dass sich die optimale Platzierung aus der Kombination von Problemgröße, Hardwarecharakteristik und Optimierungsziel ergibt. Bei sehr kleinen GEMMs ist die CPU überlegen. Bei kleinen bis mittleren GPU-relevanten Größen entsteht ein echter Konflikt zwischen der schnelleren RTX 3090 und der energieärmeren RTX 5060 Ti. Bei großen residenten GEMMs dominiert die RTX 3090 dagegen beide Zielgrößen. Innerhalb der AMD-CPU zeigen ausgewählte große Größen zusätzlich, dass laufzeit- und energieoptimale Threadcounts auseinanderfallen können.

GEMM liefert damit einen starken Crossover-Baustein für die Gesamtstudie, trägt die umfassendere These „fastest is not always greenest“ jedoch nur punktuell. Die breiteste Evidenz für Energie-Laufzeit-Konflikte ist insbesondere bei den noch auszuwertenden speichergebundenen Workloads zu erwarten. Die GEMM-Kampagne sollte daher in ihrem jetzigen Zustand eingefroren und als abgeschlossener, validierter Teil der Gesamtanalyse verwendet werden. Weitere GEMM-Messungen sind für die Gültigkeit dieses Befunds nicht erforderlich.